

所属类别	2026 年“华数杯”全国大学生数学建模竞赛	参赛编号
本科组		CM2602322

标题（此处换成论文的标题）

摘 要

超大规模集成电路（VLSI）中的**布图规划**是决定芯片性能、面积与良率的核心环节。本文针对 VLSI 布图规划问题，以模块位置、方向与形状为决策变量，以**模块互不重叠、不超出芯片轮廓**为约束，建立轮廓面积与总半周长线长（HPWL）等目标下的优化模型，并采用”多源初解生成—并行元启发优化—双向反馈定界校验—场景适配”四层求解框架及**模拟退火、迭代局部搜索、B*-树、约束规划（CP-SAT）**等方法求解。

针对问题一，建立**二维矩形装箱的字典序双目标优化模型**：以轮廓面积最小为一级目标、长宽比接近 1 为二级目标，并证明该问题为 NP-hard、最优解具有整数坐标性质。以 Skyline+ 迭代局部搜索为主算法、B*-树 + 模拟退火为对照求解。**结果表明：n100、n200、n300 的轮廓面积分别为 192818、191026、291311，packing 密度达 91.97%–93.77%，长宽比均在 1.07–1.09 之间，主算法面积较 B*-树 +SA 改进 0.34%–5.50%。**

针对问题二，

针对问题三，

最后，我们对提出的模型进行全面的评价：本文的模型贴合实际，能合理解决提出的问题，具有实用性强，算法效率高等特点，该模型在 xx,xx,xx 方面也能使用。

关键词：关键词 1 关键词 2 关键词 3 关键词 4 关键词 5

一、问题的提出

1.1 问题的背景

布图规划 (Floorplanning) 是超大规模集成电路 (VLSI) 物理设计流程中的关键环节, 其任务是在给定芯片轮廓内确定各功能模块的位置与方向, 使模块互不重叠、不超出轮廓, 并最小化芯片面积与模块间连线长度等目标。布图质量直接影响芯片的面积、性能、良率与可靠性, 是电子设计自动化 (EDA) 领域最核心的研究问题之一。布图规划属于 NP-hard 问题, 精确算法仅适用于小规模实例, 工程上普遍采用构造式启发式与模拟退火 (SA) 等元启发式方法求解。随着大规模 ASIC/SoC 采用分层设计与固定轮廓约束, 布图规划从“最小化面积”转变为“在给定轮廓内最小化总连线长度”的约束优化问题; 半周长线长 (HPWL) 因计算简便且与真实布线长度高度正相关, 成为最常用的线长评估指标。近年来, 基于泊松方程的解析方法 (PeF) 与深度强化学习布图 (AlphaChip) 进一步拓展了大规模布图的求解范式, 为布图规划的高效求解提供了新的思路。

1.2 问题重述

(1) 问题一: 在芯片轮廓不固定且模块之间无任何连接关系的前提下, 确定各矩形功能模块在芯片内的摆放位置与方向, 并且允许各个模块进行 90° 旋转, 使包围所有模块的**芯片轮廓面积最小**; 当轮廓面积相同时, 要求其**长宽比尽量接近 1**。需根据所建立的模型与 `.blocks` 文件信息, 对附件中的 `n100`、`n200`、`n300` 三组芯片分别独立完成模块摆放, 并给出三组芯片轮廓的面积、长宽比及模块摆放的可视化结果。

(2) 问题二:

(3) 问题三:

(4) 问题四:

二、问题分析

2.1 问题一分析

问题一要求在轮廓自由、模块无连接的前提下, 并且允许各个矩形模块进行 90° 旋转, 确定各矩形模块的位置与方向, 使其芯片面积最小、面积相同时长宽比尽量接近 1。因此**问题的本质**在数学上属于经典的**二维矩形装箱 (Rectangle Packing) 问题**, 即将给定矩形集互不重叠地摆放, 并确定其最小包围盒。由于包含正方形装箱为特例, 问题为 NP-hard, n 较大时无法精确求解, 必须借助启发式方法。

同时, 该问题存在两个优化目标: 主目标为**最小化芯片轮廓面积**, 次目标为**在面积相同时使长宽比尽量接近 1**。因此, 采用**字典序优化策略**: 先求解最优面积, 再在面积最优解集中优化长宽比, 严格符合题意”面积优先、长宽比次之”的要求。




图 1 问题一四层实施框架

基于上述分析，针对问题一制定**四层实施框架**，其结构如图 1所示，各层环环相扣、以具体算法与数据流落地，并以实验结果闭环验证。

2.2 问题二分析

.....

2.3 问题三分析

.....

2.4 问题四分析

.....

三、模型的假设

由于……，所以也需要遵循一定的假设

假设 1……

假设 2……

假设 3……

假设 4……

假设 5……

假设 6……

假设 7.....

四、符号说明

表 1 变量符号及其解释说明

符号	解释说明
$\mathcal{B}$	硬模块 (HardBlock) 集合
$\mathcal{T}$	固定端子 (Terminal) 集合
$\mathcal{N}$	线网集合
$\mathcal{P}_k$	线网 k 的引脚集合
n	硬模块个数
w_i, h_i	模块 i 的原始宽、高
$\hat{w}_i, \hat{h}_i$	模块 i 旋转后的实际宽、高
r_i	模块 i 的旋转标志, $r_i \in \{0, 1\}$
x_i, y_i	模块 i 左下角坐标
W, H	芯片轮廓的宽、高
A	模块总面积, $A = \sum_{i \in \mathcal{B}} w_i h_i$
S	芯片轮廓面积, $S = W \cdot H$
S^*	最优轮廓面积
ρ	packing 密度, $\rho = A/S$
δ	密度 gap, $\delta = 1 - \rho$
d	死区比例
L	正方形芯片边长, $L = \sqrt{A(1 + d)}$
X_t, Y_t	端子 t 的固定坐标
HPWL_k	线网 k 的半周长线长
λ_1, λ_2	HSA 评估函数权重系数
T	模拟退火温度
K, K'	初解生成数、粗筛保留数

五、模型的建立与求解

5.1 问题一

5.1.1 模型的建立

由于芯片是由各个模块拼接而来，因此设模块集合 $\mathcal{B} = \{1, 2, \dots, n\}$ ，模块 i 的原始宽高为 (w_i, h_i) ；决策变量为模块 i 左下角坐标 (x_i, y_i) 与旋转标志 $r_i \in \{0, 1\}$ ，其中 $r_i = 1$ 表示旋转 90° ，旋转即交换宽高。旋转后模块实际宽高为

$$\hat{w}_i = (1 - r_i)w_i + r_i h_i, \quad \hat{h}_i = r_i w_i + (1 - r_i)h_i \quad (1)$$

设芯片轮廓宽、高分别为 W, H ，模块总面积为 $A = \sum_{i \in \mathcal{B}} w_i h_i$ ，芯片轮廓总面积为 $S = W \cdot H$ 。

又因为在芯片制作是要求模块互不重叠，即 $\forall i, j \in \mathcal{B}, i < j$ ，则下述四个条件至少满足其一：

$$(x_i + \hat{w}_i \leq x_j) \vee (x_j + \hat{w}_j \leq x_i) \vee (y_i + \hat{h}_i \leq y_j) \vee (y_j + \hat{h}_j \leq y_i) \quad (2)$$

轮廓边界约束：

$$0 \leq x_i, \quad x_i + \hat{w}_i \leq W, \quad 0 \leq y_i, \quad y_i + \hat{h}_i \leq H, \quad \forall i \in \mathcal{B} \quad (3)$$

上述非重叠约束与轮廓边界约束的几何含义如图图 2所示：相邻模块在水平或竖直方向上必须保持分离以保证互不重叠，同时所有模块整体必须位于宽为 W 、高为 H 的芯片轮廓之内。




图 2 问题一约束条件示意图

在布图规划中，评价布局优劣的首要指标是芯片轮廓面积。由于题目要求在面积相同的情况下长宽比越接近 1 越好，两个目标之间存在明确的主次关系，不宜直接加权求和，故本文采用**字典序优化策略**：先最小化轮廓面积 $S = W \cdot H$ ，即

$$\min f_1 = W \cdot H \quad (4)$$

在得到最优面积 S^* 后，再在面积最优解集中进一步优化长宽比，即

$$\min f_2 = \left| \frac{W}{H} - 1 \right| \quad \text{s.t. } WH = S^* \quad (5)$$

其中 S^* 为式((4) 式)的最优值，上述两式构成字典序双目标，严格符合题意”**面积优先、长宽比次之**”的要求。

5.1.2 理论分析

为给求解算法的设计提供严谨的理论依据，本小节从计算复杂性、解空间结构与性能界三个层面，对问题一的模型性质进行分析，依次给出 NP-hard 性质、整数性引理与面积下界三个结论，并据此确定”启发式为主、精确法为辅”的求解策略。

(1) NP-hard 性质。该问题包含**经典二维矩形装箱 (Rectangle Packing)** 问题为特例。由于将正方形装箱判定问题可多项式归约到本问题，故本问题属于 NP-hard 问题。这意味着当模块规模 n 较大时，问题的解空间随 n **呈阶乘级爆炸**，精确算法（如 MILP、约束规划）在最坏情况下需要指数级时间，仅适用于小规模实例。因此在 $n = 100 \sim 300$ 的赛题规模下，无法依赖精确算法在合理时间内得到最优解，必须采用启发式与元启发式方法进行求解^[1]。这一结论直接决定了后续求解框架的总体方向，即第 1 层的多源初解构造与第 2 层的元启发式改进。

(2) 整数性引理。由**压缩 (compaction) 性质**可知，对任意可行布局，总可以依次将所有模块向左、向下压缩至无法再移动，而这一压缩过程不会破坏可行性。压缩后，每个模块的坐标必等于其左侧（或下方）若干模块的宽度（高度）之和，由于所有模块尺寸均为整数，故压缩后各模块坐标必为整数。由此可得：必然存在一个整数坐标的最优解，即最优轮廓尺寸 W^*, H^* 均为整数^[2]。这一性质将连续坐标的搜索空间离散为整数格点，使轮廓尺寸的搜索可限制在整数域上，从而为第 3 层中”在整数 S 的分解上枚举并检验可 packing 性”的定界校验提供了理论支撑。

(3) 下界与密度。由于各模块互不重叠且全部位于轮廓内部，模块总面积 $A = \sum_{i \in \mathcal{B}} w_i h_i$ 必然不超过轮廓面积，故面积最优值满足下界 $S^* \geq \lceil A \rceil$ 。据此定义 packing 密度 $\rho = A/S$ ($0 < \rho \leq 1$)，并以 **gap** = $1 - \rho$ 衡量当前解与面积下界的差距：密度越接近 1，说明空白面积越少，布局质量越高。该指标既可用于求解过程中实时判断剩余优化空间，也可用于最终结果的量化评价，使启发式求解结果的优劣具有可度量的客观标准。

综上, NP-hard 性质决定了求解必须采用启发式方法, 整数性引理将搜索空间离散化并提供了定界枚举的依据, 面积下界与密度指标则为求解过程的迭代控制与最终结果的质量评价提供了量化准则。三者共同构成问题—求解框架的” 搜索方向—搜索空间—搜索质量” 理论闭环, 为后续四层求解框架的设计奠定了完整的基础。

5.1.3 模型的求解

针对问题 NP-hard 与 $n = 100 \sim 300$ 的大规模特点, 本文采用图 1所示的四层求解框架, 各层以具体算法与数据流落地。

第 1 层: 多源初解生成池, 制造多样性。

为了丰富初始解的多样性, 该论文通过综合四种机制生成 $K \geq 10$ 个初始布局:

(1) **HSA 贪心构造**: 按评估函数 $V_i = \lambda_1 h_i w_i / (HW) + \lambda_2 (h_i + w_i) / (H + W)$ 降序装箱生成紧凑的初始 B*-树^[1];

(2) **BL/Skyline 多规则构造**: 分别按面积降序、长边降序、最小剩余空间与随机排序四种优先级各生成布局;

(3) **LFF 策略**;

(4) **初解中随机预选 90° 旋转以打破对称性。**

随后以轮廓尺寸与结构差异构造多样性指标, 粗筛保留 K' 个代表性初解进入下一层。

第 2 层: 并行多目标元启发优化层, 多起点结合精英池。

在第一层中的 K' 个初始解传入第二层之后, 对 K' 个初解各启动一条独立的元启发轨迹, 并多核并行, 以 **Skyline 结合迭代局部搜索 (ILS) 为主算法**、B*-树 + 模拟退火 (SA) 为对照算法^[3]; 两者均采用字典序目标 $(W \cdot H, |W/H - 1|)$, 并按 **Metropolis 准则** $e^{-\Delta/T}$ 接受暂时劣解以跳出局部最优。各轨迹收敛后将解放入精英池, 再以精英解为种子扰动重启, 形成” 多起点—精英池—重启” 循环直至时间预算耗尽。

第 3 层: 双向反馈定界校验层。由于只使用启发式或精确算法都存在缺点:

- 启发式算法只能给出一个可行解, 但是无法判断是否为最优解;
- 精确算法可以给出最优解, 但是在大规模问题上求解时间过长, 无法在合理时间内得到结果。

因此该论文通过**双反馈的方式**实现定界与搜索的双向闭环:

(1) **反向反馈 (搜索 $\rightarrow$ 定界)**: 第 2 层产生的任一可行布局即为**可行证书**, 给出轮廓面积上界 S_{ub} 与密度 $\rho = A/S$;

(2) **正向反馈 (定界 $\rightarrow$ 搜索)**: 由整数性引理与面积下界 $S_{lb} = \lceil A \rceil$, 实时计算当前解与下界的密度 gap $\delta = 1 - \rho$ 并回馈第 2 层, 判断剩余优化空间; 当 δ 收敛至阈值时停止, 并以 CP-SAT 在小规模子集上验证下界、给出可证明的最优性说明。

第 4 层: 场景适配接口层。

因为接下来的问题都需要在该框架上进行，所以该论文将问题一抽象为”目标函数（面积/长宽比）、约束（无重叠/边界）与形状模型（矩形 + 旋转 $\{0^\circ, 90^\circ\}$ ）”的统一配置，第 1–3 层代码仅通过开关切换适配，保证问题二至四的模型主线一致与代码复用。

5.1.4 求解结果与分析

基于上述四层框架，对附件中 n100、n200、n300 三组芯片独立求解，得到各芯片轮廓的最优摆放结果如表表 2 所示。其中 A 为模块总面积， $\rho = A/S$ 为 packing 密度， $\text{gap} = 1 - \rho$ 为与面积下界的相对差距，长宽比取 $\max(W, H)/\min(W, H)$ 。

表 2 问题一三组芯片的求解结果

数据集	n	轮廓尺寸 $W \times H$	轮廓面积 S	密度 $\rho(\text{gap})$
n100	100	421×458	192818	93.09%(6.91%)
n200	200	418×457	191026	91.97%(8.03%)
n300	300	523×557	291311	93.77%(6.23%)

(1) **求解质量分析。**三组芯片的求解结果均为可行布局，packing 密度分别达到 93.09%、91.97% 和 93.77%，即各轮廓内约 92% 以上的面积被模块有效利用，仅约 6%–8% 的空白面积作为间隙散布于模块之间。对比面积下界 $S_{lb} = \lceil A \rceil$ ，三组结果的 gap 均在 6%–8% 之间，说明该四层框架已逼近矩形装箱问题的理论极限；由于任意两个整数尺寸矩形在一般情形下无法实现面积利用率 100% 的完美铺砌，这一 gap 水平符合矩形 packing 的理论预期。同时，三组结果的长宽比分别为 1.088、1.093 和 1.065，均接近 1，满足题目”面积相同时长宽比尽量接近 1”的次目标要求。

(2) **算法对比分析。**为进一步验证四层框架（主算法 Skyline+ILS）的求解优势，将其与对照算法 B*-树 +SA 的求解结果进行对比，如表表 3 所示。

表 3 主算法与 B*-树 +SA 对照算法的轮廓面积对比

数据集	Skyline+ILS 面积	B*-树 +SA 面积	面积差	改进比例
n100	192818	193479	661	0.34%
n200	191026	195390	4364	2.23%
n300	291311	308313	17002	5.50%

由表表 3 可见，主算法在三组数据上的轮廓面积均小于 B*-树 +SA，且改进比例随模块规模增大而明显上升（0.34%→2.23%→5.50%）。这得益于四层框架的”多源初解 + 多起点精英池”策略：规模越大，解空间越复杂，单一退火轨迹越容易陷入局部

最优，而多起点并行与扰动重启机制能更充分地探索解空间，从而获得显著更优的布局。

(3) 收敛性分析。三组芯片求解过程的收敛曲线如图图 3所示。可以看出，三组曲线均呈”快速下降—缓慢逼近”的典型收敛形态：退火初期轮廓面积快速下降，搜索效率高；随着温度降低，改进幅度逐渐放缓并趋于平稳，最终收敛到稳定的最优值附近，说明四层框架的降温策略与精英池重启机制设计合理，能够在有限时间内收敛到高质量解。






图 3 问题一三组芯片的求解收敛曲线

三组芯片的模块摆放可视化结果如图图 4所示，图中矩形代表各功能模块（以编号标注），其左下角坐标即模块摆放位置。由图可见，各模块均被紧密、无重叠地排布于轮廓之内，大模块与中模块相互嵌合，空白间隙分散且细小，直观验证了求解结果的可行性与紧凑性。



(a) n100 模块摆放

(b) n200 模块摆放



(c) n300 模块摆放

图 4 问题一三组芯片的模块摆放可视化

5.2 问题二

5.2.1 方法概要

判断哪些因素会影响到购买意愿可以采用回归分析，由于因变量（购买意愿）是二分变量，应该采用 Logistic 回归。

如果将 $a_1 \sim a_8$ 、 $B_1 \sim B_{17}$ 全部变量直接代入回归方程检验，会因为变量太多导致回归效果欠佳。因此应该首先筛选出在不同购买意愿群体中有统计性差异的变量，再用筛选出的变量进行回归分析，以提高回归效果。

5.2.2 变量筛选

由第一问可知：对于不同购买意愿的群体，用户的满意度（ $a_1 \sim a_8$ ）和用户的经济情况有显著差异，因此应该将 $a_1 \sim a_8$ 以及反映用户经济情况的变量（ B_{10} 、 B_{13} 、 B_{14} 、 B_{15} 、 B_{16} 、 B_{17} ）纳入回归方程的检验中。其中 B_{10} 代表工作年限、 B_{13} 代表家庭年收入、 B_{14} 代表个人年收入、 B_{15} 家庭可支配年收入、 B_{16} 代表房贷支出比例、 B_{17} 代表车贷支出比例。

对于其他统计性差异未知的变量，如户口情况、居住区域等，应逐个进行检验。

对于分类变量（ B_1 、 B_3 、 B_5 、 B_6 、 B_{12} ），采用卡方检验，检验结果汇总如下：

表 4 品牌 1 分类变量卡方检验结果

	Pearson 卡方值	渐进显著性 (双侧)	是否纳入回归方程
B_1	0.253	0.881	否
B_3	27.136	0.000	是
B_5	3.019	0.697	否
B_6	2.796	0.834	否
B_{12}	8.766	0.554	否

表 5 品牌 2 分类变量卡方检验结果

	Pearson 卡方值	渐进显著性 (双侧)	是否纳入回归方程
B_1	1.643	0.440	否
B_3	3.584	0.465	否
B_5	2.830	0.726	否
B_6	3.082	0.687	否
B_{12}	19.338	0.036	是

综上，每个品牌中纳入回归分析的变量有：**品牌 1**： $a_1 \sim a_8$ 、 B_2 、 B_{10} 、 $B_{13} \sim B_{17}$ **品牌 2**： $a_1 \sim a_8$ 、 B_2 、 B_{10} 、 $B_{12} \sim B_{17}$ **品牌 3**： $a_1 \sim a_8$ 、 B_{10} 、 $B_{13} \sim B_{17}$

(3) 回归分析：在 SPSS 中分品牌对 (2) 中筛选出的变量进行二元 Logistic 回归分析，选取 0.1 作为显著性，认为在检验结果中 P 值小于 0.1 的变量是可能对购买意愿产生影响的变量，得到的回归结果如表 7

即，对品牌 1 来说，电池技术性能、经济性、房贷支出比例、车贷支出比例可能影响客户的购买意愿；对品牌 2 来说，电池技术性能、经济性、动力性、职位、家庭可支配收入、房贷支出比例、车贷支出比例可能影响客户的购买意愿；对品牌 3 来说，舒适性、经济性、外观内饰、工作年限、房贷支出比例可能影响客户购买意愿。

表 6 品牌 3 分类变量卡方检验结果

	Pearson 卡方值	渐进显著性 (双侧)	是否纳入回归方程
B_1	0.473	0.789	否
B_3	2.685	0.612	否
B_5	4.579	0.469	否
B_6	3.252	0.861	否
B_{12}	6.227	0.712	否

表 7 可能对购买意愿产生影响的变量

品牌	可能对购买意愿造成影响的因素
品牌 1	a_1 、 a_3 、 B_{16} 、 B_{17}
品牌 2	a_1 、 a_3 、 B_{15} 、 B_{16} 、 B_{17} 、 a_5 、 B_{12}
品牌 3	B_{16} 、 a_2 、 a_7 、 a_3 、 B_{10}

5.3 问题三

第三题采用了多种方法进行不同品牌电动汽车的客户挖掘模型的建立，主要是 CART 决策树的生成和神经网络模型两种方法

5.3.1 CART 决策树的生成

基本原理：CART 决策树的生成就是递归地构建二叉决策树的过程。结点最优划分特征的选择使用基尼指数 (Gini index)，其中主要决定各个因素对于客户模型影响的程度，考虑到此处的数据较为分散，对影响的因素根据数据大小进行分组。

先介绍基尼指数的定义：分类问题中，假设有 K 个类，样本点属于第 k 类的概率为 p_k ，则概率分布的基尼指数定义为

$$Gini(p) = \sum_{k=1}^K p_k(1 - p_k) = 1 - \sum_{k=1}^K p_k^2 \quad (6)$$

对于二分类问题，若样本点属于第 1 个类的概率是 p ，则概率分布的基尼指数为

$$Gini(p) = 2p(1 - p) \quad (7)$$

对于给定的样本集合 D ，其基尼指数为

$$Gini(D) = 1 - \sum_{k=1}^K \left(\frac{|C_k|}{|D|} \right)^2 \quad (8)$$

在此处， C_k 是 D 中属于 k 类的样本子集， K 是类的个数。

如果样本集合 D 根据特征 A 是否取某一可能值 a 被分割成 D_1 和 D_2 两部分，即

$$D_1 = (x, y) \in D | A(x) = a, D_2 = D - D_1 \quad (9)$$

则在特征 A 的条件下，集合 D 的基尼指数定义为

$$Gini(D, A) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2) \quad (10)$$

基尼指数 $Gini(D)$ 表示集合 D 的不确定性，基尼指数 $Gini(D, A)$ 表示经 $A=a$ 分割后集合 D 的不确定性。基尼指数值越大，样本集合的不确定性也就越大，这一点与熵相似。

图 5 二分类中基尼指数、信息熵、和分类误差率的关系

CART 生成算法：

输入：训练数据集 D ，停止计算的条件；

输出：CART 决策树。

根据训练数据集，从根结点开始，递归地对每个结点进行以下操作，构建二叉决策树：

(1) 设结点的训练数据集为 D ，计算现有特征对该数据集的基尼指数。此时，对每一个特征 A ，对其可能取的每个值 a ，根据样本点对 $A=a$ 的测试为“是”或“否”将 D 分割成 D_1 和 D_2 部分，利用式(10) 式计算 $A=a$ 时的基尼指数。

(2) 在所有可能的特征 A 以及它们所有可能的切分点 a 中，选择基尼指数最小的特征及其对应的切分点作为最优特征与最优切分点。依最优特征与最优切分点，从现结点生成两个子结点，将训练数据集依特征分配到两个子结点中去。

(3) 对两个子结点递归地调用 (1)，(2)，直至满足停止条件。(4) 生成 CART 决策树。

算法停止计算的条件是结点中的样本个数小于预定阈值，或样本集的基尼指数小于预定阈值 (样本基本属于同一类)，或者没有更多特征。

具体的情况如下文所示：

决策树模型结果： (1) 品牌 1: 与城市居住龄高度相关，但出来决策树效果不好，这里我加上了弱相关的因素 (Person 系数大于 0.17)

对于品牌 1，对客户购买意愿的影响因素有：房贷占比，车贷占比，电池，经济

图 6 品牌 1 决策树模型

对模型进行精度检验，得到模型评价精度 94.5，评价结果如图 7

图 7 品牌 1 决策树模型评价精度

(2) 品牌 2: 对于品牌 2, 外观, 动力, 安全, 经济, 舒适, 电池与客户购买意愿有一般正相关关系, 与房贷占比有一般负相关关系, 与个人年收入和单位有非常紧密关系, 与城市居住龄有紧密关系。

图 8 品牌 2 决策树模型

对模型进行精度检验, 得到模型评价精度 92.86, 评价结果如图 9

图 9 品牌 2 决策树模型评价精度

(3) 品牌 3: 对于品牌 3, 客户购买意愿与电池, 品质, 外观, 操控性, 动力性, 安全性, 经济型, 舒适性, 具有一般线性关系

图 10 品牌 3 决策树模型

对模型进行精度检验, 得到模型评价精度 88.89, 评价结果如图 10

对附录三中的客户数据进行预测, 预测结果为:

图 11 品牌 2 决策树模型评价精度

对于品牌 1: 2、4、5 号顾客有购买的意愿, 1、3 号顾客没有购买的意愿; 对于品牌 2: 7、10 号有购买的意愿, 6、8、9 号顾客没有购买的意愿; 对于品牌 3: 11、12 号顾客有购买的意愿, 13、14、15 号顾客没有购买的意愿

5.3.2 神经网络模型

采用神经网络模型, 其中输入的影响的因素采用的问题二中的影响因素, 并将其作为输入部分的参数, 将最后结果是否有购买意愿的 0,1 作为标签。本处使用卷积神经网络 CNN 是一种前馈神经网络, 主要原理步骤如下:

给定一个输入信号序列 x 和滤波器 f , 卷积的输出为:

$$y_t = \sum_{k=1}^m w_k x_{t-k+1} \quad (11)$$

本次采用的二维卷积如图 12:

用卷积层代替全连接层:

框图结构如图 14:

图 12 二维卷积

图 13 卷积层

图 14 卷积层

图 15 神经网络模型精度

模型的精度和损失函数的情况随着训练次数的情况如图 15所示：

由图易得随着训练次数的上升，整体的训练精度提高，但是预测精度会稍稍下降，这是因为训练的精度过高后易发生模型的过拟合现象，从曲线上看，模型整体的拟合效果较好。

利用模型进行预测结果如图 16：

图 16 神经网络模型预测结果

对于品牌 1：2、4、5 号顾客有购买的意愿，1、3 号顾客没有购买的意愿；对于品牌 2：7、10 号有购买的意愿，6、8、9 号顾客没有购买的意愿；对于品牌 3：11、12 号顾客有购买的意愿，13、14、15 号顾客没有购买的意愿

5.3.3 预测结果

第三题采用了 CART 决策树的生成和神经网络模型两种方法进行挖掘模型的拟合，两种方法的模型的拟合效果和预测效果均比较好，尤其是卷积神经网络网络，训练精度高达 96.67%，可根据训练的次数去决定训练精度和预测精度，最后的 15 名目标客户购买电动车的可能性如下：

对于品牌 1：2、4、5 号顾客有购买的意愿，1、3 号顾客没有购买的意愿；对于品牌 2：7、10 号有购买的意愿，6、8、9 号顾客没有购买的意愿；对于品牌 3：11、12 号顾客有购买的意愿，13、14、15 号顾客没有购买的意愿

5.4 问题四

第四问中需要基于这种思路和前面的研究成果，在附件 3 每个品牌中各挑选 1 名没有购买电动汽车的目标客户，实施销售策略。我们根据第三问的结果：对于品牌 1：2、4、5 号顾客有购买的意愿，1、3 号顾客没有购买的意愿；对于品牌 2：7、10 号有购买的意愿，6、8、9 号顾客没有购买的意愿；对于品牌 3：11、12 号顾客有购买的意愿，13、14、15 号顾客没有购买的意愿对模型进行优化。

5.4.1 决策树模型的优化

对于决策树模型，根据图 6 易得品牌 1 中对于城市居住年龄具有较大的影响，而后是电池、车贷占比、房贷占比。选择品牌 1 中的 3 号顾客，相对来说城市居住年龄较为饱和。相对来说车贷，房贷比较少，具有很大的提高空间，同时，电池、经济的满意度也不高，因此建议建提高对电池，经济的满意度，各提高 2.5%，发现最后结果预测结果变为有购买意愿。

图 8 中，品牌 2 中的 8 号顾客，在决策树中购买意愿占比 0.4，可在外观，动力，安全，经济，舒适，电池六个因素中选五个提升，根据决策树中不同因素的重要程度，选择外观、舒适、电池、经济、动力各增加 1%，发现最后结果预测结果变为有购买意愿。

图 10 中，品牌 3 选 13 号顾客，电池，品质，外观，操控性，动力性，安全性，经济型，舒适性，八个因素中选五个进行提升，根据决策树中不同因素的重要程度，选择电池，品质，外观，操控性，动力性，安全性，经济型，舒适性各增加 0.625%，发现最后结果预测结果变为有购买意愿，符合题意。

如图 17 为模型优化后的训练精度和测试精度的图像：对于神经网络模型：根据卷

图 17 优化的决策树模型精度

神经网络模型，对其进行补充，思路为将 5% 的满意度分割成 500 份 0.01% 进行各个影响因素之间的加权，得到最终结果最大的值。

5.5 问题五

在问题一中，对电动车的经济性满意度不高是没有购买意愿人群的普遍特点，在问题二可能对购买意愿产生影响的因素中，经济性在三个品牌中均有影响；通过对不同购买意愿人群的经济状况分析可知，经济状况较好的客户更容易有购买意愿；同时，从问题三和问题四的结果可知，不同品牌、不同用户的影响因素不同。

根据以上分析，给出如下三方面销售建议：

(1) 加强购车的经济性。完善售后服务，提供保障措施，减少客户在购车时对电动车售后维修、保养等方面高成本的顾虑，提高客户对新能源汽车经济性能好的认可度。

(2) 将市场定位在较高收入人群。在新能源汽车还没有广泛普及的今天，高收入高学历、有社会责任感、倡导绿色出行的人群更容易对新能源汽车产生购买意愿，以该人群为先导，可加快新能源汽车产业的发展。

(3) 制定精准销售模型。对于不同品牌、不同人群，购买意愿有不同的影响因子，没有固定的销售模式，应该具体事例具体分析，精确分析、精确销售。

六、参考文献

参考文献

- [1] Chen J, Zhu W, Ali M M. A Hybrid Simulated Annealing Algorithm for Nonslicing VLSI Floorplanning[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews), 2011, 41(4): 544–553.
- [2] Yao B, Chen H, Cheng C K, et al. Revisiting Floorplan Representations[C]//Proceedings of the International Symposium on Physical Design (ISPD). 2001: 138–143.
- [3] Chen T C, Chang Y W. Modern Floorplanning Based on B*-Tree and Fast Simulated Annealing[J]. IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, 2006, 25(4): 637–652.
- [4] 黄志鹏, 李兴权, 朱文兴. 超大规模集成电路布局的优化模型与算法 [J]. 运筹学学报, 2021, 25(3): 15–36.
- [5] Adya S N, Markov I L. Fixed-Outline Floorplanning: Enabling Hierarchical Design[J]. IEEE Transactions on Very Large Scale Integration (VLSI) Systems, 2003, 11(6): 1120–1135.
- [6] Li X, Peng K, Huang F, et al. PeF: Poisson’s Equation-Based Large-Scale Fixed-Outline Floorplanning[J]. IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, 2023, 42(6): 2002–2015.
- [7] Mirhoseini A, Goldie A, Yazgan M, et al. Chip Placement with Deep Reinforcement Learning[J]. Nature, 2021, 594(7862): 207–212.
- [8] Zhong R, Du X, Yan J. RulePlanner: All-in-One Reinforcement Learner for Unifying Design Rules in 3D Floorplanning[C]//Proceedings of the 43rd International Conference on Machine Learning (ICML). 2026.

附录

附录 1: 问题三的 python 代码

```
# Importing the libraries
#导入包
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd

# Importing the dataset
#取数据
dataset =pd.read_csv('C:/Users/Administrator/Desktop/chap4.csv')
#这里取桌面的chap4的代码
#这里取D到Q列
X =dataset.iloc[:,3:16].values
#这里取S列
y =dataset.iloc[:,18].values

# Splitting the dataset into the Training set and Test set
#将数据集拆分为训练集和测试集
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test =train_test_split(X, y, test_size =0.25,
                                                    random_state =0)

# Feature Scaling

from sklearn.preprocessing import StandardScaler
sc_X =StandardScaler()
X_train =sc_X.fit_transform(X_train)
X_test =sc_X.transform(X_test)

# Fitting Classifier to the Training set
#训练集的分类器拟合
from sklearn.tree import DecisionTreeClassifier
classifier =DecisionTreeClassifier(criterion ='entropy', random_state=0,
                                   class_weight={0:1,1:10})
#这里的class_weight={0:1,1:10},max_depth=20参数可以不用加入
# classifier = DecisionTreeClassifier(criterion = 'entropy', random_state=0)
classifier.fit(X_train,y_train)

# Predicting the Test set results
#预测测试集结果
y_pred =classifier.predict(X_test)

# Making the Confusion Matrix
#制作混淆矩阵
```

```

from sklearn.metrics import confusion_matrix
cm =confusion_matrix(y_test, y_pred)

scoretest =classifier.score(X_test,y_test)

from IPython.display import Image
import pydotplus
from sklearn import tree
# 可视化决策树
dot_data =tree.export_graphviz(classifier, out_file=None,
filled=True, rounded=True,
special_characters=True)
graph =pydotplus.graph_from_dot_data(dot_data)
# 显示图片
# graph.get_nodes()[7].set_fillcolor("#FFF2DD")
graph.write_png("C:/Users/Administrator/Desktop/out.png")

*决策树.
TREE
购买意愿[n]
BY
城市居住龄[s]
/ TREE
DISPLAY =TOPDOWN
NODES =STATISTICS
BRANCHSTATISTICS =YES
NODEDEFS =YES
SCALE =AUTO
/ DEPCATEGORIES
USEVALUES =[.0 1.0]
TARGET =[1.0]
/ PRINT
MODELSUMMARY
CLASSIFICATION
RISK
/ GAIN
CATEGORYTABLE =YES
TYPE =[NODE]
SORT =DESCENDING
CUMULATIVE =NO
/ SAVE
NODEID
PREDVAL
PREDPROB
ASSIGNMENT
/ METHOD
TYPE =CRT
MAXSURROGATES =AUTO

```

```

PRUNE =NONE
/ GROWTHLIMIT
MAXDEPTH =AUTO
MINPARENTSIZE =400
MINCHILDSIZE =200
/ VALIDATION
TYPE =SPLITSAMPLE(75)
OUTPUT =BOTHSAMPLES
/ CRT
IMPURITY =GINI
MINIMPROVEMENT =0.0001
/ COSTS
EQUAL
/ PRIORS
FROMDATA
ADJUST =NO

/ COSTS
EQUAL
COMPUTE
filter_$(品牌类型=2).
VARIABLE
LABELS
filter_$ '品牌类型=2 (FILTER)'.
VALUE
LABELS
filter_$ 0
'Not Selected'
1
'Selected'.
FORMATS
filter_$ (f1.0).
FILTER
BY
filter_$.
EXECUTE.

*决策树.
TREE
购买意愿[n]
BY
城市居住龄[s]
/ TREE
DISPLAY =TOPDOWN
NODES =STATISTICS
BRANCHSTATISTICS =YES
NODEDEFS =YES
SCALE =AUTO

```

```

/ DEPCATEGORIES
USEVALUES =[.0 1.0]
TARGET =[1.0]
/ PRINT
MODELSUMMARY
CLASSIFICATION
RISK
/ GAIN
CATEGORYTABLE =YES
TYPE =[NODE]
SORT =DESCENDING
CUMULATIVE =NO
/ SAVE
NODEID
PREDVAL
PREDPROB
ASSIGNMENT
/ METHOD
TYPE =CRT
MAXSURROGATES =AUTO
PRUNE =NONE
/ GROWTHLIMIT
MAXDEPTH =AUTO
MINPARENTSIZE =400
MINCHILDSIZE =200
/ VALIDATION
TYPE =SPLITSAMPLE(75)
OUTPUT =BOTHSAMPLES
/ CRT
IMPURITY =GINI
MINIMPROVEMENT =0.0001
/ COSTS
EQUAL
/ PRIORS
FROMDATA
ADJUST =NO

/ COSTS
EQUAL

COMPUTE
filter_$=(品牌类型=3).
VARIABLE
LABELS
filter_$ '品牌类型=3 (FILTER)'.
VALUE
LABELS
filter_$ 0

```

```

'Not Selected'
1
'Selected'.
FORMATS
filter_$ (f1.0).
FILTER
BY
filter_$.
EXECUTE.

*决策树.
TREE
购买意愿[n]
BY
城市居住龄[s]
/ TREE
DISPLAY =TOPDOWN
NODES =STATISTICS
BRANCHSTATISTICS =YES
NODEDEFS =YES
SCALE =AUTO
/ DEPCATEGORIES
USEVALUES =[.0 1.0]
TARGET =[1.0]
/ PRINT
MODELSUMMARY
CLASSIFICATION
RISK
/ GAIN
CATEGORYTABLE =YES
TYPE =[NODE]
SORT =DESCENDING
CUMULATIVE =NO
/ SAVE
NODEID
PREDVAL
PREDPROB
ASSIGNMENT
/ METHOD
TYPE =CRT
MAXSURROGATES =AUTO
PRUNE =NONE
/ GROWTHLIMIT
MAXDEPTH =AUTO
MINPARENTSIZE =400
MINCHILDSIZE =200
/ VALIDATION
TYPE =SPLITSAMPLE(75)

```

```

OUTPUT =BOTHSAMPLES
/ CRT
IMPURITY =GINI
MINIMPROVEMENT =0.0001
/ COSTS
EQUAL
/ PRIORS
FROMDATA
ADJUST =NO

/ COSTS
EQUAL

\end{appendixx}
\begin{appendixx}
\section{问题三的神经网络代码}
from predict import predictToolimport time
import cv2
import threadingimport time
from sensor_md import sensor_obj
import RPi.GPIO as GPIO
import time
from keras.datasets import mnist
import tensorflow as tf
from PIL import Image
import numpy as np
from tensorflow.keras.utils import to_categorical
from keras import layers
from keras import models
tf.compat.v1.disable_eager_execution()

model =models.Sequential()
model.add(layers.Conv2D(32, (3, 3), activation='relu', input_shape=(28, 28, 1)))
model.add(layers.MaxPool2D((2, 2)))
model.add(layers.Conv2D(64, (3, 3), activation='relu'))
model.add(layers.MaxPool2D((2, 2)))
model.add(layers.Conv2D(64, (3, 3), activation='relu'))
model.add(layers.Flatten())
model.add(layers.Dense(64, activation='relu'))
model.add(layers.Dense(10, activation='softmax'))
# 网络构架

model.compile(optimizer='rmsprop', loss='categorical_crossentropy', metrics=['
accuracy'])

# 编译步骤

# 准备图像数据

```

```

train_labels =to_categorical(train_labels)
test_labels =to_categorical(test_labels)
# 准备标签

model.fit(train_images, train_labels, epochs=5, batch_size=64)
test_loss, test_acc =model.evaluate(train_images, train_labels)
print('test_loss:%.6f' % test_loss)
print('test_acc:%.6f' % test_acc)

model.save(r'D:\Python for windows\homewor\cnn_mnist.pkl')

GPIO.setwarnings(False)GPIO.setmode(GPIO.BCM)#
GPIO.setup(4,GPIO.OUT, initial=GPIO.LOW)
GPIO.setup(12,GPIO.OUT, initial=GPIO.LOW)
GPIO.setup(13,GPIO.OUT, initial=GPIO.LOW)
GPIO.setup(16,GPIO.OUT, initial=GPIO.LOW)pin_avoid_obstacle =24
GPIO.setmode(GPIO.BCM)
GPIO.setup(pin_avoid_obstacle, GPIO.IN, pull_up_down=GPIO.PUD_DOWN)
def thread(cap):
    global ex
    ite =0
    while True:
        global frame
        ret, frame =cap.read()
        cv2.imshow("capture", frame)
        if cv2.waitKey(100) & 0xFF ==ord('q'):
            ex =True
            break
        cap.release()
        cv2.destroyAllWindows()
    pass

if __name__ =='_main_ ':
    ex =False
    img_pre =predictTool()
    cap =cv2.VideoCapture(0)
    threa =threading.Thread(target=thread,args=(cap,))
    threa.start()
    time.sleep(2)
    global frame
    while True:
        status =GPIO.input(pin_avoid_obstacle)
        print("zhaugntai", status)
        if not status:
            time.sleep(0.5)
        _, frame =cap.read()
        resized_img =cv2.resize(frame, (224, 224), interpolation=cv2.INTER_LINEAR)

```



```

resized_img_rgb =cv2.cvtColor(resized_img, cv2.COLOR_BGR2RGB)
id =img_pre.img_predict(resized_img_rgb)
print(id)
if 0 <=id <=5:
GPIO.output(4, GPIO.HIGH)
time.sleep(1)
GPIO.output(4, GPIO.LOW)
elif 6 <=id <=12:
GPIO.output(12, GPIO.HIGH)
time.sleep(1)
GPIO.output(12, GPIO.LOW)
elif 13 <=id <=34 and id !=28:
GPIO.output(13, GPIO.HIGH)
time.sleep(1)
GPIO.output(13, GPIO.LOW)
else:
GPIO.output(16, GPIO.HIGH)
time.sleep(1)
GPIO.output(16, GPIO.LOW)
else:
time.sleep(0.5)
print("wu")
pass
if ex:
break

import os
import json
import torch
from PIL import Image
from torchvision import transforms
from models.model import resnet101import time
BASE_DIR= os.path.dirname(os.path.abspath( file__))
device =torch.device("cuda:0" if torch.cuda.is_available() else "cpu")
class predictTool():
def _init_(self):
self.path_state_dict =os.path.join(BASE_DIR, "fine.pth" , "resNet101.pth")
self.path_classnames =os.path.join(BASE_DIR, "class_json", "class_indices.json"
                                     )self.num_classes =38
self._data_transform =transforms.Compose(
[transforms.ToTensor(),
transforms.Normalize([0.485,0.456,0.406],[0.229,0.224,0.225])])self.model =self.
__getModel()
self.class_indict =self._load_class_names()
pass
def _getModel(self):
model =resnet101(num_classes=self.num_classes).to(device)

```

```

assert os.path.exists(self.path_state_dict), "file: 't' dose not exist.".format(
    self.path_state_dict)
model.load_state_dict(torch.load(self.path_state_dict, map_location=device))
model.to(device)
model.eval()
return model

def img_predict(self, img):
    img =self.__img_process(img)
    with torch.no_grad():
        time_tic =time.time()
        output =torch.squeeze(self.model(img.to(device))).cpu()
        predict =torch.softmax(output, dim=0)
        predict_cla =torch.argmax(predict).numpy()
        time_toc =time.time()
        print(time_toc -time_tic) # 预测时间
        print_res ="class: prob: {:.3}"".format(self.class_indict[str(predict_cla)],
            predict[predict_cla].numpy())

    print(print_res)
    return int(predict_cla)

```

附 录

附录 1: 问题四的代码

```
import time
def _init_(self,trig,echo):
    self.trig =trig
    self.echo =echo
    GPIO.setmode(GPIO.BCM)
    GPIO.setup(trig,GPIO.OUT, initial=GPIO.LOW)
    GPIO.setup(echo, GPIO.IN)pass
def checkdist(self):
    try:
        GPIO.output(self.trig,GPIO.HIGH)
        time.sleep(0.000020)
        GPIO.output(self.trig,GPIO.LOW)
        while not GPIO.input(self.echo):
            pass
        t1 =time.time()
        while GPIO.input(self.echo):
            pass
        t2 =time.time()
    except:
        pass
    return ((t2 -t1)* 340/2)*100
if __name__=="_main_":
    while(True):
        time.sleep(0.5)
        k =sensor_obj(22,17)
        d =k.checkdist()
        print(d)
```